

Proyecto Final DataXperience C3G5

Presentado por:

Sofía Lorena Pinzon Suarez

Samuel Alvarado Currea

Natalia Castiblanco Mahecha

Ángel Gabriel Velásquez Salamanca

Universidad EAN

DataXperience C3G5

Facultad de Ingeniería

Bogotá D.C.

13 de septiembre de 2026

Introducción

Durante los últimos años la sociedad ha experimentado un auge acerca de las nuevas inteligencias artificiales, en donde estas han logrado posicionarse en diferentes ámbitos de la sociedad, destacándose por su gran capacidad para crear textos, imágenes, código, audio y otros contenidos a partir de una instrucción proporcionada por los usuarios. De acuerdo con esto la creación de estas herramientas basadas en este tipo de tecnología son utilizadas más frecuentemente en actividades educativas, laborales, personales, empresariales y de entretenimiento, a pesar de esto, detrás de la rapidez y facilidad con la que estos sistemas generan respuestas existe una gran infraestructura tecnológica que requiere una cantidad considerable de recursos fundamentales para funcionar.

Para el funcionamiento adecuado de estas inteligencias se requiere una arquitectura la cual se basa en un gran centro de datos, servidores y sistemas de refrigeración que requieren de energía eléctrica y de agua, paralelamente a esto es muy poco de lo que se llega a hablar acerca de los impactos que suceden en el uso de estas inteligencias, ya que lo que más destaca en la sociedad es la facilidad y la practicidad en la cual generan un gran impacto en nuestra vida diaria, es por esto que es importante empezar a tener conocimientos acerca de los impactos que suceden con su utilización. Los procesos de cómputo que se llevan a cabo en cada consulta a un modelo generativo, en función del modelo, la infraestructura y las condiciones operativas, pueden contribuir al gasto de recursos naturales y a la creación de emisiones indirectas de gases de efecto invernadero.

De acuerdo con esto se busca analizar el impacto que genera la inteligencia artificial generativa, así como entender que la utilización de estas tecnologías no es completamente inmaterial, sino que implica un consumo físico de recursos. Por esta razón, este trabajo tiene como objetivo analizar el consumo de agua y energía eléctrica relacionado con la producción de respuestas por parte de los modelos de inteligencia artificial generativa, con el fin de entender sus consecuencias para el medio ambiente y fomentar una reflexión acerca del empleo responsable y sostenible de estas tecnologías.

Preguntas de apoyo y principal para el desarrollo del proyecto

Principal:

¿Cuántos kilovatios hora (kWh) de energía eléctrica y litros (L) de agua consumieron los modelos de IA en el año 2025?

Apoyo #1

¿Cómo se compara el consumo de energía entre modelos según el tipo de GPU usado (NVIDIA vs. Google TPU) ?

Apoyo #2

¿Qué tareas de benchmark presentan mayor consumo?

Apoyo #3

¿Cuáles son los 10 modelos con mayor consumo total de energía (kWh) según el dataset?

Las preguntas de apoyo están basadas en lograr explicar de forma gráfica y mostrar su tendencia o comportamiento de forma más clara.

Búsqueda y obtención de los datos (fuente y justificación).

La búsqueda de datos para este proyecto no fue instantánea. En un principio, se halló una fuente de datos sobre el consumo energético de modelos de IA. Sin embargo, al examinar, se determinó que era muy restringida para llevar a cabo un análisis exhaustivo (pocas variables o registros significativos para responder a la pregunta de investigación), por lo que no se consideró factible seguir con ella.

A partir de esto, se realizó una búsqueda más exhaustiva de fuentes públicas y confiables sobre consumo energético e hídrico de modelos de IA generativa, hasta encontrar el **ML.ENERGY Benchmark v3**, un proyecto de investigación de código abierto liderado por la **Universidad de Michigan**, disponible públicamente en Hugging Face ([ml-energy/benchmark-v3](https://huggingface.co/ml-energy/benchmark-v3)).

Esta fuente se seleccionó como definitiva por las siguientes razones:

- **Volumen y variedad de datos:** contiene 838 registros de corridas reales, sobre 34 modelos de IA generativa distintos y 2 tipos de GPU (NVIDIA H100 y B200), muy superior en cobertura a la primera fuente evaluada.
- **Mediciones reales, no estimadas:** los datos de energía provienen de mediciones directas sobre hardware físico durante la ejecución de los modelos, no de cálculos teóricos o aproximaciones.
- **Origen académico verificable:** al ser un proyecto de investigación universitario de código abierto, la metodología de medición está documentada y es auditable, lo que da mayor confiabilidad al análisis frente a una fuente sin respaldo institucional.
- **Acceso estructurado:** el dataset se puede consultar directamente en Python mediante la librería oficial `mlenergy-data`, conectada al repositorio de Hugging Face, sin necesidad de descargar archivos masivos de texto de forma manual.

Cabe aclarar que el consumo de **agua** no viene medido directamente en el dataset original: se calculó a partir de la energía consumida, aplicando el factor estándar de conversión reportado por Google Cloud (1.08 litros de agua por cada kWh consumido para tareas de refrigeración). Este cálculo se detalla en la sección de limpieza y preparación de datos

Comprensión del conjunto de datos y descripción de las variables.

El ML.ENERGY Benchmark v3 es la fuente de los datos empleados, que consta de 16 columnas y 838 registros en total (cada registro equivale a una ejecución individual de un modelo de inteligencia artificial generativa). Cada fila representa la implementación de un modelo de

lenguaje en una tarea concreta, incluyendo las mediciones correspondientes de potencia, velocidad y energía.

El dataset incluye **34 modelos de IA generativa distintos** (entre ellos familias como Qwen 3, DeepSeek y Llama), ejecutados sobre **2 tipos de GPU NVIDIA: H100 y B200**, en **5 tareas de benchmark diferentes**: *gpqa* (preguntas científicas complejas), *lm-arena-chat* (chat conversacional), *image-chat* (análisis de imágenes), *source graph-fim* (autocompletar código) y video-chat (análisis de video).

A continuación se describen las variables principales del conjunto de datos:

Variable	Tipo de dato	Descripción
<code>model_name / model_id</code>	Texto	Nombre e identificador único del modelo evaluado
<code>gpu_model</code>	Texto	Tipo de GPU utilizada en la corrida (H100 o B200).
<code>task</code>	Texto	Tarea de benchmark ejecutada.
<code>architecture</code>	Texto	Tipo de arquitectura del modelo (Dense, MoE o Híbrida).
<code>num_gpus</code>	Numérica (discreta)	Número de GPUs usadas simultáneamente en la corrida.
<code>energy_joules_total</code>	Numérica	Energía total consumida durante la corrida, en julios.
<code>energy_joules_per_request</code>	Numérica	Energía estimada por cada consulta/prompt, en julios.
<code>energy_joules_per_token</code>	Numérica	Energía consumida por cada token generado, en julios.
<code>avg_power_watts</code>	Numérica	Potencia promedio de la GPU durante la corrida, en vatios.
<code>throughput_tokens_per_second</code>	Numérica	Velocidad de generación de texto, en tokens por segundo.

r_sec		
energy_kwh_total, energy_kwh_per_request	Numérica	Energía convertida a kilovatios-hora
agua_litros_total, agua_litros_per_request	Numérica	Consumo de agua estimado a partir de la energía
es_b200	Numérica (binaria)	Variable creada para el modelo de clasificación: 1 si la corrida fue en B200, 0 si fue en H100.

Tabla 1. Explicación de variables usadas en el conjunto de datos.

En cuanto a la calidad de los datos: el diagnóstico inicial reveló que no hay valores nulos en el conjunto de datos (0.0% en las 16 columnas), lo que indica una buena procedencia. No obstante, se identificaron valores atípicos (outliers): la columna `energy_joules_per_request` tiene 122 casos atípicos (14.56% del total), lo que significa que las corridas tienen un consumo de energía por consulta que se desvía significativamente de los valores comunes del resto de los datos. Esto es porque, según la tarea (como analizar un video en comparación con un chat simple), el costo energético de una sola consulta puede fluctuar considerablemente. Por lo tanto, no son errores de captura, sino variaciones auténticas del fenómeno que se está evaluando. Esta observación se aborda nuevamente en la sección de limpieza y en el análisis exploratorio.

Proceso completo de limpieza y preparación de los datos.

1. El dataset ML, a diferencia de otros conjuntos de datos, no contiene valores nulos ni errores en la escritura. ENERGY Benchmark v3 se presentó sin valores nulos (0.0% en las 16 columnas). Por esto, el proceso de limpieza no se enfocó en eliminar o completar datos faltantes, sino en tres actividades diferentes: filtrar registros incompletos por motivos de seguridad, transformar tipos de datos con seguridad y unificar las unidades de medida para que todas las operaciones subsiguientes pudieran ser comparadas.

2. A pesar de que el diagnóstico inicial no reveló nulos, se implementó un filtro sobre la columna `energy_joules_total` (la variable base de todo el análisis) como medida de seguridad, desechando cualquier fila que pudiera aparecer sin este valor:

```
df = df.dropna(subset=["energy_joules_total"])
```

Esto garantiza que ningún cálculo posterior (conversión a kWh, cálculo de agua, promedios, etc.) se rompa por falta de este dato esencial.

3. Las columnas de energía (`energy_joules_total`, `energy_joules_per_request`, `energy_joules_per_token`) se convirtieron explícitamente a tipo numérico con `pd.to_numeric(..., errors="coerce")`. Esta función busca transformar cada valor en número, y si se topa con algo que no puede ser convertido (por ejemplo, un texto donde debería ir un número o un valor mal escrito), lo convierte en nulo en vez de interrumpir el proceso debido a un error. Esta etapa es una red de seguridad: aunque el conjunto de datos parezca limpio, salvaguarda el análisis ante posibles fallos ocultos que podrían surgir si la fuente de datos se modificara más adelante.

4. El conjunto de datos original mide la energía en Julios, lo que no es una unidad intuitiva para comparar con el consumo diario de electricidad. Utilizando la equivalencia física, se transformó a kilovatios-hora (kWh), que es la unidad en la que generalmente se factura la electricidad:

```
df["energy_kwh_total"] = df["energy_joules_total"] / 3_600_000
```

```
df["energy_kwh_per_request"] = df["energy_joules_per_request"] / 3_600_000
```

Este paso es fundamental para que los resultados del proyecto (por ejemplo, "267 kWh utilizados en 2025") tengan sentido y puedan ser contrastados con referencias familiares, como el uso de electricidad al mes de una casa.

- Como el dataset no contempla una medición directa del agua, se determinó como una variable derivada de la energía. Para ello, se utilizó el factor estándar proporcionado por Google Cloud (WUE, Water Usage Effectiveness): 1.08 litros de agua por cada kWh consumido para enfriar los centros de datos.

$$\text{agua_litros} = \text{energia_kwh} \times 1.08$$

Análisis exploratorio de datos (EDA) y Hallazgos

Una vez limpios los datos, se realizó un análisis exploratorio con el objetivo de responder la pregunta principal y las tres preguntas de apoyo planteadas al inicio del proyecto. A continuación se presenta cada gráfico generado, junto con su interpretación.

Panel de KPIs: consumo total en 2025


Consumo total de energía y agua — Dataset ML.ENERGY 2025



Gráfica 1. Panel KPIs en consumo total de energía y agua

De acuerdo con el panel de indicadores, los modelos de IA generativa usaron 267 kWh de energía eléctrica y aproximadamente 288 litros de agua en las 838 corridas analizadas. Para poner esta cifra en perspectiva: 267 kWh representa el consumo eléctrico mensual de una vivienda media en Colombia, lo que evidencia que, a pesar de ser una muestra relativamente pequeña de corridas de prueba, la IA generativa ya alcanza un consumo agregado similar al del hogar durante un mes entero.


Consumo de energía por tipo de GPU (H100 vs. B200)



Gráfica 2. Comparativa de consumo por modelo de GPU (Graphic Processing Unit)

La B200 utilizó 164 kWh en total, mientras que la H100 usó 102 kWh, lo que significa que consumió un 61% más de energía. El patrón es el mismo en la estimación de agua consumida: 177 litros para B200 y 110 litros para H100. Esto responde directamente a la primera pregunta de apoyo (comparación por tipo de GPU): La B200, al ser una tarjeta con mayor capacidad computacional, también conlleva un costo adicional más alto en términos de energía y agua.


Consumo por tarea de benchmark



Gráfica 3. Consumo total de energía (kWh) por tarea de benchmark

Cuando el consumo fue categorizado y filtrado de acuerdo con el tipo de tarea, se descubrió una jerarquía clara: gpqa (preguntas científicas complejas) ocupó la primera posición con 108 kWh, después siguieron lm-arena-chat (72 kWh) e image-chat (58 kWh); sourcegraph-fim (autocompletar código, 17 kWh) y video-chat (12 kWh), en cambio, quedaron muy por debajo. Este descubrimiento es relevante porque contradice una intuición común: cabría esperar que el análisis de video (una tarea "pesada" en términos de datos) requiere más energía que responder preguntas de razonamiento científico. Sin embargo, sucede lo contrario; el tipo de procesamiento cognitivo requerido por la tarea tiene más influencia que la clase de contenido procesado.


Top 10 modelos con mayor consumo total de energía



Gráfica 4. Ranking de modelos con mayor consumo total de energía

El modelo con más consumo individual fue el Qwen 3 235B A22B Thinking FP8, que consumió 39 kWh, y después se ubicaron modelos similares de la misma familia. Una observación significativa es que seis de los diez modelos más consumistas pertenecen a la familia Qwen 3. Esto indica que la arquitectura o el tamaño de este conjunto de modelos implica un costo energético estructuralmente superior al de otras familias analizadas, como Llama o DeepSeek.

Eficiencia energética por modelo (Julios por token)




Gráfica 5. Ranking de eficiencia energética de modelos de Inteligencia Artificial

No es lo mismo ser ineficiente que consumir una gran cantidad de energía total; un modelo puede acumular más energía simplemente porque atendió a más consultas. Por esta razón, se comparó la energía consumida por cada token producido. El resultado revela una disparidad de

más de 50 veces entre el modelo más eficiente y el menos eficaz (por ejemplo, Qwen 3 Coder 480B A35B FP8 consume 12.2 julios por token, mientras que GPT OSS 20B solo emplea 0.095 julios por token). Esto demuestra que "modelo de mayor tamaño o más consumidor en total" no es lo mismo que "modelo menos eficiente por unidad de trabajo"; el tamaño y la estructura (densa vs. MoE) son más relevantes que el consumo bruto.


Velocidad vs. consumo energético (relación inversa)



Gráfica 6. Velocidad comparada con el consumo energético de los modelos por GPU

El diagrama de dispersión que relaciona la energía por token con la velocidad de generación (tokens por segundo) evidencia una correlación inversa: a más velocidad, menos energía se utiliza por cada token. En el análisis estadístico (sección 6), este patrón fue confirmado numéricamente más adelante, con un coeficiente de correlación de -0.35.


Potencia promedio por tipo de GPU



Gráfica 7. Potencia de los modelos dependiendo de su GPU

Se midió la "intensidad" de cada GPU en términos de vatios instantáneos, además del consumo acumulado. El promedio de funcionamiento de la B200 es 2,330 W, un 52 % más que el de la H100 (1,537 W). Esta variación de la potencia instantánea, junto con el consumo total más elevado evidenciado en 5.2, confirma que la B200 es una tarjeta que requiere significativamente más en ambas direcciones: cuánto consume y qué tan fuerte funciona en cada instante.

Distribución de energía por prompt (consulta individual)




Gráfica 8. Distribución energética por prompt

Se examinó el gasto promedio de energía de una única consulta a un modelo de inteligencia artificial. El histograma señala que la mayor parte de las consultas se agrupan en niveles de consumo individual muy bajos, con una cola larga hacia la derecha; esto significa que hay ciertas consultas individuales mucho más costosas que las demás (conforme a los outliers hallados en el apartado 4.5), mientras que la mayoría de los intercambios diarios con la IA poseen un costo energético individual bastante bajo.

Matriz de correlación

Matriz de confusión: ¿el modelo adivina bien la GPU?




Gráfica 9. Matriz de práctica por confusión

Esta es una matriz de confusión del modelo de clasificación (regresión logística) para predecir el tipo de GPU (H100 o B200) a partir del perfil de consumo energético de cada corrida. La matriz contrasta la GPU real (True label, en el eje vertical) con la GPU que predijo el modelo (Predicted label, en el eje horizontal), utilizando como base el conjunto de prueba (168 corridas, lo que equivale al 20% de los datos). Los valores que se encuentran en la diagonal (51 y 48) corresponden a las predicciones precisas: el modelo detectó con precisión 51 de 81 corridas reales de H100 y 48 de 87 corridas reales de B200. Los errores están fuera de la diagonal: 39 corridas de B200 fueron clasificadas erróneamente como H100 y 30 corridas de H100 fueron clasificadas erróneamente como B200.

Análisis Estadístico Realizado

Matriz de correlación

Para entender cómo se relacionan entre sí las tres variables numéricas centrales del análisis (energy_joules_per_token, avg_power_watts y throughput_tokens_per_sec), se calculó una matriz de correlación, con los siguientes resultados:



Gráfica 10. Matriz correlativa entre variables relacionadas al consumo energético

- Energía por token en comparación con potencia (0.51): correlación positiva moderada: los modelos que requieren más energía por token suelen ejecutarse en GPUs con mayor potencia de funcionamiento.
- Energía por token frente a velocidad (-0.35): correlación negativa moderada: confirma, en términos numéricos, el patrón que se observó en la sección 5.6 del análisis exploratorio: cuanto más rápida es la generación, menos energía se utiliza por token.
- Potencia vs. Velocidad (-0,05): casi no hay relación: la velocidad de generación y la potencia de la GPU resultan ser, para sorpresa de todos, casi independientes entre sí.

Comparación estadística por GPU (principio del cuarteto de Anscombe)

Siguiendo el principio del cuarteto de Anscombe (que consiste en cuatro conjuntos de datos que muestran estadísticas iguales, pero formas totalmente diferentes al graficarse), no se consideró suficiente el resumen numérico por sí mismo, sino que se realizó una comparación explícita entre las dos GPUs en términos de correlación, dispersión y media.

```
print(resumen_por_gpu)
```

***	media_velocidad	std_velocidad	media_energia_token \
gpu_model			
B200	3797.71	4264.97	1.99
H100	2989.93	2712.43	1.32

	std_energia_token	correlacion
gpu_model		
B200	3.52	-0.350
H100	2.09	-0.425

Gráfica 11. Ejecución del código

A pesar de que las correlaciones entre energía por token y velocidad son parecidas en ambas GPUs (-0.35 en B200 y -0.42 en H100), se descubrió un hallazgo significativo que no muestra el promedio solo: En B200, la desviación estándar de la velocidad (4,264.97) es más alta que su media (3,797.71), pero en H100 la dispersión (2,712.43) es más proporcional a su media (2,989.93). Esto señala que el desempeño de la B200 es mucho más cambiante entre diferentes tareas, es "impredecible" estadísticamente hablando, a diferencia de la H100, que tiene una conducta más constante. Este tipo de descubrimiento ratifica la relevancia de estudiar no solamente la media, sino también la dispersión total de los datos, como lo indica el principio de Anscombe.

Selección del modelo y justificación de su elección

Como parte de complemento para el desarrollo del análisis exploratorio y estadístico, se tomó la decisión de realizar un planteamiento en forma de pregunta que permita identificar o poder caracterizar de forma más clara el perfil de consumo de energía y agua que menos conviene a la hora de utilizar modelos de Inteligencia Artificial generativa, tomando en cuenta todos los factores ya mencionados como la energía por token, la potencia promedio y la velocidad en generación general. Queremos conocer si ¿es posible inferir el tipo de GPU utilizado?, con nuestras dos opciones principales (H100 o B200) tomamos como mejor método para la identificación una

regresión de tipo logística que nos permite tomar un modelo por medio del sistema binario (sólo dos valores posibles), donde 1 corresponde al modelo de GPU B200 y 0 corresponde a la ejecución con la GPU H100.

Además de esta facilidad de toma de decisiones para dos valores únicamente, también es necesario aclarar que tenemos más razones para utilizar este tipo de regresiones, primero, es un modelo de fácil interpretación que nos permite entender dirección y magnitud con la que cada variable, en este caso de consumo, influye para cada probabilidad de uso de cualquiera de los dos modelos seleccionados. Segundo, permite tener más control tomando en cuenta que es un problema de tamaño moderado donde el modelo de regresión logística suele tener muy poco riesgo de precisión. Y, por último, nos permite establecer de forma coherente una base explicable que tiene que ver más con la estrategia de sustentación para un proyecto académico, permitiendo hacer análisis antes de ir de lleno a modelos de mucha mayor complejidad.

Finalmente, el objetivo de este modelo se toma en un sentido no predictivo o aplicado, es decir, no se busca reemplazar la etiqueta normal de las estadísticas o características del modelo de GPU, es simplemente exploratorio por lo que su labor principal es evaluar patrones e identificar comportamientos, no cambiarlos ni ajustarlos de forma conveniente. Esto prepara la investigación para hacerla más confiable, pues al revisar patrones de consumo lo suficientemente distintos entre ambos modelos, los separa automáticamente permitiendo realizar complementos a gráficas con las que ya contamos (2 y 7) que muestran diferencias sustanciales o bajas de acuerdo con su evaluación (de modelos H100 y B200).

Aplicación del Modelo

Con respecto a la aplicación del modelo utilizado, hicimos uso de las columnas numéricas relacionadas con el consumo como las variables predictoras: `energy_joules_per_token`, `avg_power_watts` y `throughout_token_per_sec` (las mismas que fueron analizadas en la matriz de correlación vista en la sección anterior). Se estableció como variable objetivo `es_b200`. Para realizar este análisis de aplicación, el conjunto entero de datos se dividió en 80% para entrenamiento y un 20% para pruebas, utilizando la variable `train_test_split` de la librería

scikit_learn con un planteamiento fijo que garantiza la materialización teórica del resultado. Como se mencionó anteriormente, usamos la regresión logística, por lo que tiene sentido entrenarlo con LogisticRegression () en la configuración base o predeterminada, sin ajustes adicionales que puedan causar variabilidades en parámetros, nuevamente retomando que el carácter del proyecto es meramente exploratorio.

Dentro del ejercicio de aplicación, se dio utilidad al siguiente código, que, si bien no determina a completitud la aplicación entera del modelo, si nos permite identificar el uso de la regresión logística, el establecimiento de las variables y los diferentes parámetros de prueba y entrenamiento de los cuales hicimos uso.

Código:

```

X = df [[“energy_joules_per_token”, “avg_power_watts”, “throughput_tokens_per_sec”]]
y = df [“es_b200”]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 42)
modelo = LogisticRegression()
modelo.fit(X_train, y_train)
y_pred = modelo.predict(X_test)

```

El resultado de clasificación sobre el conjunto de prueba se resume en la matriz presentada en la Gráfica 9 (Matriz de confusión).

Evaluación del modelo e interpretación de los resultados

A partir de la matriz de confusión (Gráfica 9) se tomaron valores para cálculos de métricas estándar de clasificación para cada clase, en la siguiente tabla se muestran los resultados.

Clase	Precisión	Recall	F1-Score	Soporte (total)
H100	0,567 (56,7%)	0,630 (63%)	0,596	81
B200	0,615 (61,5%)	0,552 (55,2%)	0,582	87

Tabla 2. Métricas calculadas del modelo de clasificación por medio de la regresión logística

Estos cálculos fueron realizados de la siguiente manera, tomando de referencia la Precisión del H100, primero, tomamos los aciertos totales de H100 encontrados en la matriz de confusión (51), posteriormente, tomamos este valor y lo dividimos en todo lo que el modelo predijo como H100 ($51 + 39 = 90$), entonces tendríamos, $51 / 90 = 0,567$, que corresponde al 56,7% de precisión para este caso en particular.

Ahora bien, para los cálculos del Recall (nuevamente tomando el H100 de referencia), tomamos todos los aciertos del H100 (51) y lo dividimos por todos los datos H100 reales ($51 + 30 = 81$), de este modo tenemos $51 / 81 = 0,630$ que corresponde el 63% de Recall en el H100. Estos cálculos pueden realizarse de igual forma con la modelo alternativa (B200) de la misma forma y usando los datos de la matriz de confusión de forma mostrada con el ejemplo (H100). El F1-score corresponde a la media de precisión y recall, por ende, simplemente tomamos los datos así: $2(\text{Precisión del modelo} * \text{Recall del modelo}) / (\text{Precisión del mismo modelo} + \text{Recall del mismo modelo})$. Finalmente, el Accuracy global, es la suma diagonal total dividida por la suma del total de valores que tenemos en la matriz de confusión.

En lo que atañe a la interpretación de los resultados, tenemos que la exactitud global mostrada del modelo ($99/168 = 0,589$) que corresponde a un 58,9%, tenemos que utilizar de referencia comparativa la línea base, es decir, si el modelo simplemente hubiera predicho siempre la clase de mayoría o mayoritaria, habría acertado un total de 51,8% de las veces lo que significaría que la regresión logística habría superado apenas 7 puntos porcentuales la predicción imprecisa, esto sugiere un rendimiento débil o desempeño poco firme. A pesar de los resultados, si existe y se guarda cierta coherencia con las gráficas que observamos más atrás en la presentación, (Gráficas 2, 5 y 7), que nos dicen que aunque en promedio el B200 consume más que el H100, hay una diferencia considerable entre ambas distribuciones (como en la gráfica 6 donde los puntos azules y naranjas se mezclan entre sí). Por otro lado, también es importante mencionar que, bajo esta circunstancia, el tipo de GPU no fue el único factor que determinó el consumo de energía, la tarea, el modelo de IA y el número de gpus influyen de forma directa y constituyen una parte importante, sin embargo, estos resultados se mostraron de esta forma porque no fueron incluidos los factores mencionados en las variables predictoras.

Para terminar, el modelo nos confirma de forma cuantitativa un hallazgo de carácter cualitativo, es decir, hay una diferencia real pero no absoluta en el perfil de consumo que pueden tener las GPUs, esa diferencia por sí sola es muy diminuta y no podría ser suficiente para clasificar la precisión. Esto se podría mejorar en un proyecto futuro mediante el uso de más variables que nos permitan acercarnos un poco más a un resultado directo y de mucha más precisión estadística

Conclusiones y Recomendaciones

Conclusiones

1. El tipo de GPU utilizada influye de forma clara en el consumo, el modelo B200 consumió un 61% más energía total que el modelo H100, además, operó con una potencia promedio de 52% mayor, esto nos confirma la capacidad computacional que puede tener el modelo que por obvias razones tiene un costo energético o hídrico en proporción mucho más alto.
2. Los 10 modelos con mayor consumo total están dominados por la familia Qwen 3, habiendo un total de 6 dentro de los 10 tomados, esto sugiere que la arquitectura y el tamaño de esta familia implican un costo energético naturalmente más alto.
3. El tipo de tarea que más suele consumir o pesar para los modelos de inteligencia artificial son los contenidos muy procesados, esto incluye preguntas científicas de mucha complejidad, incluyendo cambios de formato, exigencias de volumen o procesamiento cognitivo.
4. El intento que tuvo el grupo por predecir el tipo de GPU por medio de la regresión logística y a partir del perfil de consumo energético obtuvo apenas una exactitud del 58% aproximadamente, un poco superior a la línea base establecida, confirmando que aunque hayan diferencias del modelo de GPU, el consumo energético no es por sí solo un parámetro que nos brinde toda la información que requerimos para poder determinar el consumo de forma más precisa y coherente, faltando datos como tareas, arquitecturas, cantidad, etc.

Recomendaciones

1. Priorizar el uso de modelos que tengan una mejor eficiencia energética por token, para tareas que tengan que ver con el uso cotidiano
2. Fomentar la transparencia por parte de los proveedores de la Inteligencia Artificial generativa sobre el consumo energético e hídrico en las regiones de sus modelos, esta información suele ser difícil de encontrar o incluso no está disponible para el usuario.
3. Para trabajos futuros, utilizar mucha más amplitud de los modelos de clasificación incorporando variables que tengan mucha más relevancia y puedan aportar valores únicos y a pesar de la redundancia, más valor notorio de análisis, esto nos ayudaría a mejorar la capacidad predictiva y el entendimiento de los factores determinantes en el consumo energético e hídrico.

Referencias

- Tipos de máquinas de GPU.* (s. f.). Google Cloud Documentation.
<https://docs.cloud.google.com/compute/docs/gpus?hl=es-419>
- PassMark Videocard Benchmarks - Videocard TDP Chart - Performance / Power.* (s. f.).
https://www.videocardbenchmark.net/power_performance.html
- Ortega, C. (2023, 6 julio). *Matriz de correlación: Qué es, cómo funciona y ejemplos.* QuestionPro.
<https://www.questionpro.com/blog/es/matriz-de-correlacion/>
- Arce, J. I. B. (2025, 3 diciembre). *La matriz de confusión y sus métricas.* Juan Barrios.
<https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>
- Torres, A. (2021, 9 diciembre). *Limpieza de datos en Pandas: Explicado con ejemplos.* freeCodeCamp.org. <https://www.freecodecamp.org/espanol/news/limpieza-de-datos-en-pandas-explicado-con-ejemplos/>
- E, F. B. C. (s. f.). *Redacción y presentación de informes.*
https://www.scielo.sa.cr/scielo.php?script=sci_arttext&pid=S1409-12592003000200007
- Normas APA – 7ma (séptima) edición.* (s. f.). <https://normas-apa.org/>
- Amazon Web Services. (s. f.). *¿Qué es el machine learning?* Amazon Web Services, Inc.
<https://aws.amazon.com/es/what-is/machine-learning/>
- Ortega, C. (2023a, febrero 25). *Análisis de regresión: Qué es, tipos y cómo realizarlo.* QuestionPro. <https://www.questionpro.com/blog/es/analisis-de-regresion/>